

面向跨城市选址推荐的语义桥接与长尾自适应排序融合方法

刘士源

学号：202400300201

山东大学软件学院

济南, 中国

2279732927@qq.com

摘要

选址推荐旨在预测品牌在目标城市中适合开设门店的候选区域，但有限的品牌、区域和门店记录使其容易受到数据稀疏影响。原论文提出 OTC，通过最优传输对齐不同城市的品牌和区域表示，以迁移其他城市的推荐经验。本文首先复现 OTC-MF 在 OpenSiteRec 上的 MF 与跨城市迁移流程，并在固定数据划分和 MF 分数矩阵的基础上，提出 TermBridge-FGWRec：一种结合可复现语义 term 特征、品牌 TermBridge、区域 FGW 迁移与城市-长尾自适应 RRF 融合的轻量改进方法。该方法保留本地 MF 作为主排序器，将语义和迁移分数作为互补的重排序信号，并按目标城市中的品牌流行度组自适应选择融合权重。在 OpenSiteRec 的 Chicago、NYC、Singapore 和 Tokyo 四个城市实验中，最终方法将平均 Recall@20 从 0.2428 提升到 0.2534，将平均 nDCG@20 从 0.1366 提升到 0.1401。进一步的消融实验表明，语义 term、跨城市迁移和长尾分组融合均对最终结果有贡献，提升主要集中在长尾和中等流行度品牌上。

关键词

选址推荐；跨城市推荐；最优传输；语义桥接；长尾推荐；排序融合

1 引言

选址推荐 (site recommendation) 是面向商业品牌的区域推荐任务，其目标是根据已有门店分布、品牌属性和城市区域信息，为品牌推荐适合开设新门店的候选区域。与面向互联网用户的大规模推荐不同，选址推荐中的交互对象通常是品牌和城市区域。在一个城市中，品牌数量、区域数量和已有门店数量都相对有限，因此训练数据天然稀疏。这种稀疏性会导致单城市推荐模型难以学习稳定的品牌偏好和区域表示，尤其是在长尾品牌或门店数量较少的城市中更为明显。

原论文 [3] 针对这一问题提出了 OTC (Optimal Transport enhanced Cross-city) 框架。OTC 的核心思想是利用多个城市之间的共性，通过最优传输学习源城市与目标城市之间的品牌对齐和区域对齐，再将源城市中学习到的推荐知识迁移到目标城市。该方法的一个重要优点是轻量：跨城市模块主要在每个城市的推荐模型训练完成后进行计算，不需要重新训练一个大型联合模型。不过，在复现和后续实验过程中可以观察到，OTC 的对齐依据主要来自训练得到的 ID embedding 几何结构。当目标城市或某些品牌的数据较稀疏时，embedding 结构可能不够稳定，跨城市迁移分数也容易出现波动。因此，一个自然的问题是：能否在原有 ID embedding 对齐之外，引入更显式、更可解释的语义辅助信号，从而使跨城市推荐更加稳定？

围绕这一问题，本文完成了两部分工作。第一，按照原论文的任务设定和 OpenSiteRec 数据集，复现 MF 与 OTC-MF 相关流程，并将 MF 基线重新对齐到较稳定的水平。第二，在复现基线的基础上，提出一种基于品牌语义桥接与区域结构迁移

的城市-长尾自适应排序融合方法。该方法构造品牌和区域的 term 特征，用语义相似性为品牌和区域对齐提供辅助信息；同时保留本地 MF 分数作为主排序信号，避免语义分支或迁移分支单独较弱时破坏本地排序。最终，我们使用 RRF (Reciprocal Rank Fusion) 将本地排序、语义排序和迁移排序进行融合，并根据目标城市中品牌交互数量划分 Tail/Mid/Head 三组，为不同城市 and 不同流行度组选择不同的融合权重。

本文的主要贡献可以概括如下：

- 复现并整理了原论文 OTC-MF 在 OpenSiteRec 上的实验设置，重新训练并保存了 MF 基线模型、分数矩阵和实验种子，为后续改进实验提供统一对比基础。
- 提出一种语义 term 桥接的跨城市推荐改进思路，用显式语义信息补充仅依赖 ID embedding 的隐式对齐结构。
- 设计城市-长尾自适应 RRF 融合策略，将语义信号和迁移信号作为本地 MF 的重排序辅助项，并对 Tail/Mid/Head 品牌采用不同权重。
- 在四个城市上进行主结果、分城市、分流行度组和消融实验，验证最终方案相比 MF 基线具有稳定提升。

2 相关工作与原文概述

2.1 选址推荐

选址推荐是推荐系统在商业地理决策中的一个具体应用。其输入通常包括品牌、已有门店、城市区域、区域属性和商业环境等信息，输出则是品牌在目标城市中可能适合开店的区域排序。由于真实商业环境中品牌和区域数量远小于常规电商推荐中的用户和物品数量，选址推荐更容易受到数据稀疏问题影响。早期方法往往依赖人工设计的地理、交通、竞争和商业特征，但这类方法可扩展性较弱，难以快速适配大量品牌和城市。在隐式反馈推荐中，BPR 是经典的成对排序目标 [5]，LightGCN 则以简化图传播增强协同表示 [2]；本文选择与原论文一致的 MF 作为主要复现骨干，以隔离跨城市模块的贡献。

2.2 跨城市迁移推荐

跨城市推荐试图利用源城市中的数据缓解目标城市的数据不足。关键困难在于，不同城市之间的区域集合通常完全不同，品牌集合也只存在部分重叠。因此，模型无法像普通跨域推荐那样直接共享同一个用户或物品 ID 空间。OTC 通过最优传输解决这一问题：它不要求源城市和目标城市有完全相同的品牌或区域，而是根据各自训练出的 embedding 结构学习软对齐关系，再将源城市推荐分数投影到目标城市。最优传输为不同支持集上的概率分布对齐提供了统一工具 [4]，FGW 则进一步允许特征与内部关系结构共同参与对齐。

2.3 原论文 OTC-MF 的核心思想

原论文将选址推荐形式化为品牌-区域二部图上的 Top-K 推荐问题。对于目标城市 t 中的品牌 b 和区域 r ，MF 基线使用品牌向量和区域向量的内积得到预测分数：

$$\hat{y}_{b,r}^t = \mathbf{u}_b^t \top \mathbf{v}_r^t. \quad (1)$$

在跨城市场景中，OTC 对源城市 s 和目标城市 t 分别计算品牌传输矩阵 $T_B^{s \rightarrow t}$ 和区域传输矩阵 $T_R^{s \rightarrow t}$ 。通过这两个传输矩阵，可以将源城市中的品牌和区域表示投影到目标城市空间，从而得到源城市到目标城市的迁移推荐分数。最后，OTC 将目标城市本地推荐分数和来自多个源城市的迁移分数加权融合：

$$\hat{P}_{final}^t = \hat{P}_{local}^t + \sum_{s \neq t} \gamma_{s,t} \hat{P}_{transfer}^{s \rightarrow t}. \quad (2)$$

该框架的优势在于能够利用其他城市的数据缓解目标城市稀疏问题。但在复现实验中，我们也注意到其迁移效果依赖于训练得到的 embedding 几何结构。如果某些品牌或城市的数据较稀疏，embedding 结构不稳定，迁移排序就可能引入噪声。这也是本文改进方案引入显式语义 term 和长尾自适应融合的主要动机。

3 问题定义

设城市集合为 $\mathcal{C}$ 。对每个城市 $c \in \mathcal{C}$ ，给定品牌集合 $\mathcal{B}^c$ 、区域集合 $\mathcal{R}^c$ 和品牌-区域交互集合 $\mathcal{E}^c$ 。若品牌 b 在区域 r 中存在至少一个门店，则记 $(b, r) \in \mathcal{E}^c$ 。任务目标是在目标城市 t 中，对每个品牌 $b \in \mathcal{B}^t$ ，从候选区域集合中推荐 Top- K 个最可能适合开店的区域。

本文遵循原论文的 all-ranking 评估协议。对于每个测试品牌，训练集中已经出现过的正样本区域不参与候选排序，其余区域作为候选集合。评价指标为 Recall@20 和 nDCG@20。Recall@20 衡量测试正样本中有多少比例被 Top-20 推荐列表覆盖；nDCG@20 进一步考虑命中结果在推荐列表中的位置，越靠前命中得分越高。两个指标均为越高越好。

为统一符号，记 X^c 为城市 c 的品牌-区域交互矩阵， S_{local}^c 为本地 MF 分数， S_{sem}^c 为语义匹配分数， $S_{transfer}^{s \rightarrow t}$ 为源城市 s 到目标城市 t 的迁移分数。 $\mathbf{z}_b$ 和 $\mathbf{z}_r$ 分别表示品牌与区域 term 特征向量， $A_B^{t \leftarrow s}$ 表示目标品牌从源城市取参考的 TermBridge， $T_R^{s \rightarrow t}$ 表示区域 FGW 传输矩阵； R_{local} 、 R_{sem} 和 $R_{transfer}$ 统一表示相应分数经 RRF 转换后的排序分数， $g(b)$ 表示品牌流行度组。

4 方法

本文最终方法可以概括为：**基于品牌语义桥接与区域 FGW 迁移的城市-长尾自适应排序融合方法**。本文将该方法记为 TermBridge-FGWRec，其中“Rec”阶段具体采用 City-Tail Adaptive RRF Fusion (CTF)；这一命名同时保留跨城市双桥接结构与最终有效的长尾自适应融合模块。它并不试图完全替代原有 MF 或 OTC-MF，而是在对齐后的 MF 基线上引入语义 term 和跨城市迁移信号，并通过保守的重排序融合提高稳定性。

整体上，TermBridge-FGWRec 保留目标城市本地 MF 分数 S_{local}^t 作为主排序信号；随后基于品牌和区域 term 特征构造本地语义匹配分数 S_{sem}^t ；同时，对每个源城市 s ，利用品牌 TermBridge $A_B^{t \leftarrow s}$ 和区域 FGW 传输矩阵 $T_R^{s \rightarrow t}$ 将源城市分数 S^s 投影为迁移分数 $S_{transfer}^{s \rightarrow t}$ 。最后，三类分数先转化为 RRF 排序分数，再由目标城市和品牌流行度组对应的权重进行自适应融合。图 1 将这一计算链条概括为 Semantic Dual Bridge、Reliable Transfer 和 City-Tail Adaptive Fusion 三个模块。

本文的设计并非一次性确定，而是由复现实验中的三个现象逐步形成。第一，单独使用 semantic-only 或 transfer-only 分支时，指标不足以替代本地 MF，说明辅助信息更适合用于重排序；第二，不同源城市的迁移收益差异明显，必须显式估计源城市可靠性；第三，Tail、Mid 和 Head 品牌对辅助信号的需求不同，统一融合权重会掩盖这种差异。因此，最终方案遵循“本地排序为主、语义与迁移为辅、可靠性控制迁移、城市与长尾组联合选权”的设计原则。

表 1 总结本文方法与原 OTC-MF 的主要区别。本文没有抛弃最优传输框架，而是将品牌侧改为显式语义桥接，将区域侧扩展为同时考虑语义和结构的 FGW，并在最终排序阶段增加源城市筛选与长尾自适应控制。

4.1 复现基线与总体框架

首先，我们在每个城市上独立训练 MF 模型，得到本地品牌 embedding、区域 embedding 和本地预测分数矩阵。该步骤是整个方法的基础，因为后续语义分数和迁移分数均作为本地 MF 排序的辅助信号。在多次复现实验后，本文将保存的单城市矩阵分解基线简称为 MF Base，其平均结果为 Recall@20 = 0.2428，nDCG@20 = 0.1366。

复现流程采用 OpenSiteRec 官方发布的城市数据划分与测试列表。MF 阶段保存每个城市的品牌、区域 embedding 及完整分数矩阵；OTC-MF 阶段依据训练得到的 embedding 构造城市内距离，计算品牌和区域传输计划，再将各源城市分数映射到目标城市。由于公开实现环境、负采样、模型选择和训练停止条件等细节可能不同，本文复现结果与原论文报告值存在一定差距。为隔离训练随机性，后续所有新增模块均固定数据划分并复用同一批 MF 分数矩阵，只比较重排序模块带来的变化。

4.2 语义 Term 表示构造

原始 OpenSiteRec 数据包含品牌名称、POI 类别和品牌-区域训练交互，但没有直接提供品牌竞争关系、相关品牌关系或完整区域邻接标签。因此，本文不人为伪造这类关系，而是从数据中可验证的字段构造语义 term 特征 (semantic term proxy)。该 term 空间也可以替换为由大语言模型生成的品牌和区域描述；但为保证当前实验可离线复现，本文最终实现采用确定性的 23 维 term 特征，而非在线调用 LLM。表 2 给出其中具有代表性的维度。

对于品牌 b ，我们从其名称和多级类别字段提取 term 特征向量，并对同一品牌的观测进行平均和 ℓ_2 归一化，得到 $\mathbf{z}_b$ 。对于区域 r ，仅使用训练集内落在该区域的品牌 term 聚合，同时加入由 POI 密度、品牌多样性等训练统计得到的区域属性：

$$\mathbf{z}_r = \text{Norm} \left((1 - \rho) \frac{1}{|\mathcal{B}_r|} \sum_{b \in \mathcal{B}_r} \mathbf{z}_b + \rho \mathbf{h}_r \right), \quad (3)$$

其中 $\mathbf{h}_r$ 表示区域密度、多样性与竞争代理统计， ρ 控制统计项比例。构造过程不读取测试边，避免将待预测门店信息泄露到 term 特征中。

原始 term 的各维区分能力不同，因此进一步使用训练正负区域对学习维度权重，并在全局权重和城市局部权重之间插值。最终 term 特征为原始表示与校准表示的归一化组合；插值系数通过训练内部的权重选择代理确定。这一过程形成从原始 term 特征到校准 term 特征的增强变体，为后续语义匹配和跨城市对齐提供统一特征空间。




Figure 1: TermBridge-FGWRec 总体框架。方法通过品牌 TermBridge 和区域 FGW 构建跨城市语义-结构双桥，并结合源城市可靠性控制与城市-长尾自适应 RRF 融合，生成目标城市 Top-20 推荐区域。

Table 1: 原 OTC-MF 与本文 TermBridge-FGWRec 的方法对比。

模块	原 OTC-MF	本文方法
品牌迁移	基于 ID embedding 的 GW 对齐	基于 term 相似度的 TermBridge
区域迁移	GW 结构对齐	FGW 语义与结构联合迁移
显式语义	无独立 term 分支	Brand/Region term 匹配
负迁移控制	固定迁移融合为主	源城市可靠性与伪验证筛选
最终融合	城市级迁移分数加权	城市-长尾组自适应 RRF

Table 2: 语义 term 特征的代表性维度。

类型	term 示例	含义
商业场景	office, shopping, tourism	品牌或区域偏好的商业场景
服务人群	office_worker, student, commuter	主要服务或吸引的人群
消费属性	premium, low_price, daily_need	消费层级、价格与需求频率
交通商业	high_traffic, transport_hub, dense_commercial	人流、交通与商业密度
竞争互补	high_competition, complementary_business	竞争程度与互补商业环境

与仅依赖 ID embedding 的隐式结构相比，term 特征的优点是可解释性更强。例如，咖啡、饮品、快餐等品牌之间在语义空间中可以具有更高相似度；商业环境相近的区域也可以被分

配更接近的表示。这些信息有助于缓解稀疏交互下 embedding 结构不稳定的问题。

4.3 本地语义分支

基于归一化后的 term 特征，目标城市内部的语义辅助分数定义为

$$S_{sem}^t(b, r) = (\mathbf{z}_b^t)^\top \mathbf{z}_r^t. \quad (4)$$

该分数并不直接作为最终推荐结果，而是用于重排序阶段。实验诊断显示，semantic-only 分支单独使用时效果较弱，但与本地 MF 结合后能够提供有效补充。

4.4 TermBridge 品牌语义桥接

原 OTC 主要依赖 ID embedding 的几何结构对齐品牌。本文在品牌侧改用显式 term 相似性建立 TermBridge。对于目标品牌 b 和源城市品牌 b' ，先计算余弦相似度，只保留相似度最高的 Q 个源品牌，再通过温度参数 τ 归一化：

$$A_B^{t \leftarrow s}(b, b') = \begin{cases} \frac{\exp(\text{sim}(\mathbf{z}_b^t, \mathbf{z}_{b'}^s)/\tau)}{\sum_{j \in \text{TopQ}(b)} \exp(\text{sim}(\mathbf{z}_b^t, \mathbf{z}_j^s)/\tau)}, & b' \in \text{TopQ}(b), \\ 0, & \text{otherwise.} \end{cases} \quad (5)$$

4.5 区域 FGW 迁移

区域侧既要考虑区域 term 的直接相似，也要保持城市内部区域之间的相对结构，因此采用融合 Gromov-Wasserstein (FGW) 求解区域传输矩阵 $T_R^{s \rightarrow t}$ 。对源城市区域 i, j 和目标城市区域 k, l ，定义城市内部结构代价与跨城市特征代价为

$$\begin{aligned} C_R^s(i, j) &= 1 - \cos(\mathbf{z}_i^s, \mathbf{z}_j^s), \\ C_R^t(k, l) &= 1 - \cos(\mathbf{z}_k^t, \mathbf{z}_l^t), \\ M_R^{s,t}(i, k) &= 1 - \cos(\mathbf{z}_i^s, \mathbf{z}_k^t). \end{aligned} \quad (6)$$

其中 C_R^s 和 C_R^t 描述两个城市内部区域的语义结构， $M_R^{s,t}$ 描述跨城市区域的直接语义差异。FGW 传输计划由下式确定：

$$\begin{aligned} T_R^{s \rightarrow t} &= \arg \min_{T \in \Pi(p, q)} (1 - \beta) \langle M_R^{s,t}, T \rangle \\ &\quad + \beta \sum_{i, j, k, l} (C_R^s(i, j) - C_R^t(k, l))^2 T_{ik} T_{jl}. \end{aligned} \quad (7)$$

参数 β 平衡特征一致性与结构一致性。实验中取 $\beta = 0.35$ ，并将每个源区域的传输计划稀疏到 Top-10 后重新归一化。

给定源城市 MF 分数矩阵 S^s ，从源城市到目标城市的迁移分数写为

$$S_{transfer}^{s \rightarrow t} = A_B^{t \leftarrow s} S^s T_R^{s \rightarrow t}. \quad (8)$$

该式分别解决品牌集合和区域集合不重合的问题：品牌语义桥将目标品牌映射到语义相近的源品牌，FGW 将源区域分数投影到目标区域空间。

4.6 源城市可靠性与负迁移控制

并非每个源城市都适合迁移到同一目标城市。本文综合品牌相似可靠性、区域 FGW 距离和训练内代理增益估计源城市权重。记 $B_{s,t}^{(b)}$ 为目标品牌 b 与源城市 Top- Q 品牌的 term 相似可靠性， $d_{s,t}^{FGW}$ 为区域传输距离， $\Delta_{s,t}$ 为试探性加入该源城市后在训练内部代理边上的指标增益，则未归一化可靠性写为

$$\tilde{Y}_{s \rightarrow t}^{(b)} = \left(B_{s,t}^{(b)} \right)^p \exp \left(- \frac{d_{s,t}^{FGW}}{\tau_R} \right)^q G(\Delta_{s,t}), \quad (9)$$

其中 $G(\Delta) = \text{clip}(1 + \kappa \Delta, g_{min}, \infty)$ ；若 Δ 低于剪枝阈值，则令该源城市可靠性为 0。最终按品牌在所有源城市上归一化：

$$Y_{s \rightarrow t}^{(b)} = \frac{\tilde{Y}_{s \rightarrow t}^{(b)}}{\sum_{u \neq t} \tilde{Y}_{u \rightarrow t}^{(b)} + \epsilon}. \quad (10)$$

其中 p, q, κ, τ_R 为可靠性平滑超参数，本文采用固定经验值调节品牌相似、区域可靠性与训练内部代理增益的相对影响；最终语义与迁移权重 α, λ 仍由城市-长尾组的内部代理边选择。

式 (9) 分别从品牌级、区域级和排序级衡量源城市可靠性：品牌级可靠性由目标品牌与源城市 Top- Q 品牌的 term 相似度给出，区域级可靠性由 FGW 距离的指数衰减给出，排序级可靠性由训练内部代理增益给出。若某源城市的代理增益低于阈值，则其可靠性置为 0；其余源城市按式 (10) 进行品牌级归一化。实现中，为避免极端情况下迁移分支完全为空，若所有源城市均低于阈值，则保留综合可靠性最高且迁移权重较小的源城市作为回退；最终是否产生明显影响仍由 $\lambda_{t,g(b)}$ 控制。

这种设计把“是否迁移”和“迁移多少”分开处理：前者由训练内代理增益筛选，后者由品牌与区域结构可靠性决定，从而降低不相似城市造成负迁移的风险。

4.7 RRF 排序融合

由于本地分数、语义分数和迁移分数的数值尺度并不完全一致，直接线性加权原始分数可能不稳定。因此本文采用 RRF 对不同分支的排序结果进行融合。RRF 是经典的基于名次的排序融合方法 [1]，能够在无需校准原始分数尺度的情况下组合多个排序列表。实验诊断表明，semantic-only 和 transfer-only 排序不能稳定超过 MF Base，因此二者不作为主推荐器，而仅用于调整本地 Top-20 附近的候选顺序。这一设计保留了 MF 对历史交互的拟合能力，同时允许 term 特征和跨城市信息提供补充。给定一个候选区域在某个排序分支中的名次 $\text{rank}(b, r)$ ，其 RRF 分数定义为：

$$\text{RRF}_K(b, r) = \frac{1}{K + \text{rank}(b, r)}. \quad (11)$$

最终融合排序分数为：

$$\begin{aligned} R_{final}^t(b, r) &= R_{local}^t(b, r) + \alpha_{t,g(b)} R_{sem}^t(b, r) \\ &\quad + \lambda_{t,g(b)} \sum_{s \in S_t} Y_{s \rightarrow t}^{(b)} R_{transfer}^{s \rightarrow t}(b, r), \end{aligned} \quad (12)$$

其中， R_{local}^t 、 R_{sem}^t 和 $R_{transfer}^{s \rightarrow t}$ 分别表示本地 MF、语义分支和跨城市迁移分支经过 RRF 后的排序分数。 $\alpha_{t,g(b)}$ 是语义分支权重， $\lambda_{t,g(b)}$ 是迁移分支权重， $Y_{s \rightarrow t}^{(b)}$ 表示源城市到目标城市的迁移可靠性权重。 $g(b)$ 表示品牌 b 在目标城市中的流行度分组， S_t 表示经过可靠性筛选后为目标城市 t 保留的源城市集合。

4.8 城市-长尾自适应权重

不同城市的数据规模和商业分布存在明显差异，同一城市中不同品牌的交互数量也差异很大。因此，使用一组固定融合权

重并不理想。本文根据目标城市中品牌的训练交互数量将品牌划分为三组：

- Tail: 交互数处于后 25% 的品牌；
- Mid: 交互数处于中间 50% 的品牌；
- Head: 交互数处于前 25% 的品牌。

为选择权重，我们从每个品牌的训练交互中固定随机种子 2026 抽取 20% 作为内部代理边；交互少于 4 条的品牌不参与选权。由于 MF Base 已使用完整训练集训练，这些边并非严格独立的重新训练验证集，而是在固定候选分数上选择融合权重的训练内部代理。官方测试边仅用于最终评价，不参与 term 特征构造、源城市筛选、融合权重选择或任何超参数选择。对每个目标城市和每个品牌组，分别网格搜索 α 和 λ ；若多个配置的内部代理目标相同，则优先选择 $\alpha + \lambda$ 更小的配置，以减少不必要的辅助干预。直觉上，Head 品牌的本地 MF 排序通常更可靠，因此融合应更保守；Tail 和 Mid 品牌的数据更稀疏，更可能从语义和跨城市迁移中受益。最终微调结果也支持这一点：Tail 和 Mid 组的指标提升明显大于 Head 组。

最终融合只在本地 MF 的 Top-200 候选边界内进行，边界外候选不允许仅凭辅助分支进入结果。此外，为避免辅助分支破坏本地 MF 已经排在最前面的高置信候选，最终方法将 `protect_top` 设为 5，即固定保留本地排序最靠前的 5 个候选及其相对优先级。RRF 参数最终选择 $K = 30$ 。

4.9 训练与推理流程

算法 1 给出最终 TermBridge-FGWRec 的推理与融合流程。

Algorithm 1 TermBridge-FGWRec 推理与融合流程

Require: 目标城市 t ，源城市集合 $\mathcal{S}_t$ ，本地分数 S_{local}^t ，品牌/区域 term 特征 z_b, z_r ，源城市分数 $\{S^s\}$

Ensure: 每个目标品牌的 Top-20 推荐区域

- 1: 由 term 匹配计算 S_{sem}^t ，并将 S_{local}^t, S_{sem}^t 转换为 R_{local}^t, R_{sem}^t
- 2: **for** 每个源城市 $s \in \mathcal{S}_t$ **do**
- 3: 构造品牌 TermBridge $A_B^{t \leftarrow s}$
- 4: 求解区域 FGW 传输 $T_R^{s \rightarrow t}$
- 5: $S_{transfer}^{s \rightarrow t} \leftarrow A_B^{t \leftarrow s} S^s T_R^{s \rightarrow t}$
- 6: 估计可靠性 $\gamma_{s \rightarrow t}^{(b)}$ ，并将迁移分数转换为 $R_{transfer}^{s \rightarrow t}$
- 7: **end for**
- 8: 按目标城市训练交互将品牌划分到 Tail/Mid/Head 组 $g(b)$
- 9: 使用训练内部代理边选择 $\alpha_{t, g(b)}$ 与 $\lambda_{t, g(b)}$
- 10: 按式 (12) 融合 R_{local}^t, R_{sem}^t 与 $R_{transfer}^{s \rightarrow t}$
- 11: 在本地 Top-200 内重排，并设置 `protect_top=5`
- 12: **return** 每个目标品牌的 Top-20 区域

5 实验设置

5.1 数据集

本文使用原论文中的 OpenSiteRec 数据集。该数据集包含 Chicago、New York City、Singapore 和 Tokyo 四个城市的品牌、区域和 POI 信息。原论文报告的数据规模如表 3 所示。

本文直接采用官方发布的预处理数据划分和测试列表，不在改进实验阶段重新划分数据。所有新增策略均在相同 `split`、相同候选集合和相同评估协议下与复现 MF 基线比较。

Table 3: OpenSiteRec 数据集统计。

城市	品牌数	区域数	POI 数
Chicago	969	801	8,044
New York City	2,702	2,325	14,189
Singapore	1,922	2,043	9,912
Tokyo	4,861	3,036	26,765

5.2 评价指标

本文使用 Recall@20 和 nDCG@20 作为主要评价指标。Recall@20 反映模型能否覆盖真实测试区域，nDCG@20 反映模型能否将真实测试区域排在更靠前的位置。由于选址推荐最终输出的是候选区域排序，nDCG@20 对推荐列表前部排序质量更敏感。

5.3 实现细节

本文首先在每个城市上独立训练 MF，并保存随机种子、模型参数、embedding 和完整分数矩阵。为保证公平性，所有语义增强与跨城市迁移实验均复用同一批本地 MF 分数，不重新训练基线。

term 特征仅由训练可见的品牌名称、类别和品牌-区域交互构造；区域 term 特征聚合训练区域中的品牌 term 特征，并加入 POI 密度和品牌多样性统计。训练内部代理边使用固定随机种子 2026，从满足条件的品牌训练交互中抽取 20%；它们只用于固定分数上的权重选择，不代表重新训练后的独立验证集。官方测试边仅用于最终评价，不参与任何特征构造、源城市筛选或参数选择。

最终配置采用 Tail/Mid/Head = 25%/50%/25%， $K = 30$ ，并将 `protect_top` 设为 5，重排序边界为本地 Top-200。对每个目标城市和流行度组分别搜索语义权重 α 与迁移权重 λ ；配置并列时选择 $\alpha + \lambda$ 更小者。所有结果均在同一候选集合上报告 Recall@20 和 nDCG@20。

5.4 模型变体

为验证各模块作用，本文设置五类模型变体：Raw Term Fusion、Calibrated Term Fusion、City-Tail RRF Fusion、Quantile-group Fusion 和 Final TermBridge-FGWRec。它们分别对应原始 term、校准 term、城市-长尾自适应融合、分位数组策略以及最终稳健微调版本。所有变体均复用前述固定 MF 分数与评估协议，仅改变 term 处理或融合策略。实验发现，单独提高 term 特征在训练正负样本上的 pair-level 区分能力，并不一定直接转化为 Top-20 排序收益，因此最终方法将本地、语义和迁移分数统一转换为 RRF 排序信号。

6 实验结果与分析

6.1 原论文报告结果

表 4 给出原论文中 MF 与 OTC-MF 在四个城市上的报告结果。可以看到，原论文中 OTC-MF 相比 MF 在各城市均有提升，说明跨城市迁移能够缓解单城市数据稀疏问题。这也是本文复现和改进工作的基础。

6.2 复现差距与公平比较范围

原论文数值用于验证量级和观察 OTC 的理想收益，但不直接作为本文新增策略的调参基线。我们的 MF 复现平均 Recall@20 为 0.2428，比论文 MF 低 0.0059；平均 nDCG@20 为 0.1366，比

Table 4: 原论文报告的 MF 与 OTC-MF 结果。

方法	Chicago		NYC		Singapore		Tokyo		Average	
	R@20	nDCG@20	R@20	nDCG@20	R@20	nDCG@20	R@20	nDCG@20	R@20	nDCG@20
MF	0.2494	0.1465	0.1702	0.0917	0.4430	0.2351	0.1323	0.0781	0.2487	0.1379
OTC-MF	0.2669	0.1599	0.1766	0.0981	0.4574	0.2503	0.1372	0.0796	0.2595	0.1470

Table 5: 与原论文报告结果的对齐比较。

方法	来源	R@20	nDCG@20	$\Delta R@20$	$\Delta nDCG@20$
Paper MF	原论文	0.2487	0.1379	-	-
Paper OTC-MF	原论文	0.2595	0.1470	+0.0108	+0.0091
Our MF Base	本文复现	0.2428	0.1366	-	-
Our Final	本文方法	0.2534	0.1401	+0.0106	+0.0035

论文低 0.0013。最终方案达到 0.2534/0.1401，超过本文同一实现、同一 split 下的 MF 基线，但仍低于原论文 OTC-MF 的 0.2595/0.1470。因此，本文不声称在绝对数值上超过原论文 OTC-MF，而是把贡献限定为：在固定复现基线和完全相同评估条件下，验证语义桥接、FGW 迁移与长尾自适应融合能够稳定改善本地 MF。这种比较范围也解释了为什么后续所有模型变体均复用同一批 MF 分数、官方测试列表和数据划分。

复现过程中还发现，MF 与 OTC-MF 的结果对数据划分粒度、是否去重品牌-区域对、负采样方式、early stopping 和训练随机种子较敏感。因此，本文固定同一官方 split、同一 MF 分数矩阵和同一 all-ranking 评估协议，所有新增模块只改变候选重排序结果。

可以看到，本文最终方法的绝对结果仍低于原论文 OTC-MF，说明本文并未在绝对数值上超过原论文方法。但是，从相对各自 MF 基线的增益看，原论文 OTC-MF 的平均 Recall@20 增益为 0.0108，而本文最终方法的增益为 0.0106，两者在 Top-20 覆盖能力提升上接近；本文 nDCG@20 增益为 0.0035，低于原论文 OTC-MF 的 0.0091。这说明本文方法更主要地改善候选覆盖，而前排排序质量仍有提升空间，也进一步限定了其作为轻量重排序增强模块的定位。

6.3 最终主结果

表 6 给出本文复现与改进过程中的主要模型变体。在对齐后的 MF 基线上，早期 raw term 和 global calibrated term 只能带来较小提升。进一步加入城市-长尾 RRF 融合后，平均 Recall@20 提升到 0.2476。采用分位数长尾组后提升到 0.2532。最终 TermBridge-FGWRRec 在小范围稳健性验证后达到 0.2534 的 Recall@20 和 0.1401 的 nDCG@20。

相对于 MF Base，最终方法的平均 Recall@20 提升 0.0106，平均 nDCG@20 提升 0.0035。换算为相对提升，Recall@20 提高约 4.37%，nDCG@20 提高约 2.56%。虽然该提升幅度不属于大幅度跃升，但在所有新策略均保持相同数据 split、相同 MF 基线和相同评估协议的条件下，该结果是稳定且可解释的。更重要的是，后续分组分析显示提升主要来自 Tail 和 Mid 品牌，这与本文方法设计动机一致。

6.4 分城市结果

表 7 给出最终方案在四个城市上的详细结果。Chicago、NYC 和 Singapore 的 Recall@20 均有提升，其中 Singapore 的提升最明显，Recall@20 提升 0.0269，nDCG@20 提升 0.0088。Tokyo 的

Recall@20 基本持平，但 nDCG@20 小幅提升，说明最终融合没有明显破坏排序质量。除 Tokyo 的 Recall@20 基本持平外，其余三个城市均取得正向 Recall 提升；四个城市的 nDCG@20 均未下降，说明该融合策略不会为了提升个别城市而明显破坏其他城市的排序。这也说明源城市可靠性控制与 $\lambda_{t,g(b)}$ 的城市-分组权重在一定程度上抑制了不可靠迁移。

6.5 长尾分组分析

表 8 给出 Tail、Mid 和 Head 三组品牌上的平均结果。可以看到，Tail 组 Recall@20 提升 0.0170，nDCG@20 提升 0.0057；Mid 组 Recall@20 提升 0.0109，nDCG@20 提升 0.0032；Head 组提升相对较小。这说明本文方法更主要地改善了数据较稀疏的品牌，而不是简单地依赖头部品牌拉高平均指标。

这一结果支持了城市-长尾自适应融合的必要性。对于 Head 品牌，本地 MF 已经拥有相对充分的训练数据，因此过强的语义或迁移干预可能反而引入噪声。对于 Tail 和 Mid 品牌，本地交互较少，语义 term 和跨城市迁移更容易提供有用补充。需要注意，三组 Recall 的绝对值不能直接解释为任务难度高低，因为各组测试正样本数量、候选区域分布和品牌覆盖程度并不相同。本文关注的是同一组内 MF Base 与最终方法的相对变化；Tail 和 Mid 的增益明显高于 Head，支持辅助信号主要改善低交互品牌的判断。Head 组提升较小并不意味着方法失效，而是说明高交互品牌的本地 MF 表示已经较充分，辅助分支需要更保守地介入；这也解释了为什么本文采用与 $g(b)$ 相关的 $\alpha_{t,g(b)}$ 和 $\lambda_{t,g(b)}$ 。

6.6 消融实验

表 9 给出关键模块消融结果。为保持比较口径清晰，w/o semantic branch 和 w/o transfer branch 均以 Full fixed-group fusion 为共同基准；City-level fusion、City-tail quantile fusion 和 Final TermBridge-FGWRRec 则用于比较融合结构与最终微调，而不是同一基准上的单模块删除。去掉 semantic 分支后，平均 Recall@20 从 0.2514 降到 0.2452，nDCG@20 从 0.1396 降到 0.1374，说明语义 term 是重要贡献来源。去掉 transfer 分支后，指标也下降到 0.2478 和 0.1385，说明跨城市迁移仍然有效。将分组自适应融合替换为 city-level 融合后，结果为 0.2483 和 0.1387，低于 quantile group 版本，说明按品牌流行度分组选择融合权重是必要的。

此外，semantic-only 和 transfer-only 分支单独使用时效果较弱，无法替代本地 MF。这表明语义信息和迁移信息更适合作为重排序辅助信号，而不是直接作为主推荐模型。因此，本文最终采用“local first, semantic/transfer rerank”的融合策略。

Table 6: 主要阶段结果对比。

方法	主要变化	Avg R@20	Avg nDCG@20
MF Base	本地 MF	0.2428	0.1366
Raw Term Fusion	加入原始 term 语义分支	0.2453	0.1372
Calibrated Term Fusion	校准 term 特征权重	0.2454	0.1374
City-Tail RRF Fusion	城市-长尾自适应 RRF	0.2476	0.1387
Quantile-group Fusion	分位数 Tail/Mid/Head	0.2532	0.1400
Final TermBridge-FGWRc	稳健验证后的最终配置	0.2534	0.1401




Figure 2: 代表性方法变体相对 MF Base 的绝对增益：(a) Recall@20；(b) nDCG@20。采用独立坐标轴后，可以更清楚地观察两个指标的阶段性变化；分位数策略带来主要提升，最终稳健微调进一步取得小幅增益。




Figure 3: Final TermBridge-FGWRc 相对 MF Base 的增益分析：(a) 分城市增益；(b) 分品牌流行度组增益。

6.7 稳健性验证

最终阶段不再改变模型结构，只对最终模型做小范围验证。分组比例设置包括三种方案：20%/60%/20%、25%/50%/25%和30%/50%/20%。RRF 参数取 $K \in \{25, 30, 35\}$ 。protect_top 的候选值为 $\{4, 5, 6\}$ ，同时比较不同验证目标函数。最优结果仍出现在 25%/50%/25% 分组、 $K = 30$ 和 protect_top=5 附近。使用 Recall+2×nDCG 作为验证目标时，最终平均结果仍为 0.2534/0.1401。这说明当前结构已经较稳定，继续大范围调参可能更多是在当前 split 上过拟合。上述验证不引入新的测试集选择，仅用于确认最终配置并非由单一超参数偶然造成。

Table 7: 最终方案的分城市结果。

城市	Recall@20			nDCG@20		
	MF	Final	Δ	MF	Final	Δ
Chicago	0.2348	0.2469	+0.0121	0.1460	0.1498	+0.0038
NYC	0.1658	0.1694	+0.0037	0.0884	0.0896	+0.0012
Singapore	0.4383	0.4652	+0.0269	0.2360	0.2448	+0.0088
Tokyo	0.1324	0.1323	-0.0001	0.0759	0.0762	+0.0003
Average	0.2428	0.2534	+0.0106	0.1366	0.1401	+0.0035

Table 8: 不同流行度品牌组上的结果。

组别	Recall@20			nDCG@20		
	MF	Final	Δ	MF	Final	Δ
Tail	0.3163	0.3332	+0.0170	0.1686	0.1742	+0.0057
Mid	0.2388	0.2497	+0.0109	0.1178	0.1210	+0.0032
Head	0.1478	0.1501	+0.0023	0.1168	0.1178	+0.0010

Table 9: 关键模块与融合结构的消融结果。

变体	说明	Avg R@20	Avg nDCG@20
Full	完整设置	0.2514	0.1396
w/o semantic	无语义	0.2452	0.1374
w/o transfer	无迁移	0.2478	0.1385
City-level	城市级权重	0.2483	0.1387
Quantile group	分位数组	0.2532	0.1400
Final	最终设置	0.2534	0.1401

7 讨论

与原论文报告结果的对比可以看到，本文方法在 Recall@20 上取得了接近原 OTC-MF 的相对增益，但 nDCG@20 增益仍明显较小。这说明当前方法更擅长将更多潜在正样本提升到 Top-20 候选集合中，而对列表前部精细排序的改善仍有限。原因可能在于本文采用保守的 RRF 重排序，而没有重新训练品牌和区域 embedding；语义 term 和迁移信号更多影响候选边界，较少改变本地 MF 已经排在前列的区域顺序。换言之，本文方法更擅长把潜在正样本推入 Top-20，而不是重新塑造 Top-5 或 Top-10 的精细顺序。

本文实验表明，跨城市迁移并不是在所有情况下都天然有效。如果直接依赖迁移分数，容易受到源城市差异、embedding 对齐噪声和长尾品牌不稳定表示的影响。因此，最终方法采用较保守的融合策略：本地 MF 仍然是主排序信号，语义和迁移分数只在 RRF 重排序中提供辅助。这种设计虽然不会产生极大的指标跃升，但具有更好的稳定性和可解释性。

从消融结果看，语义 term 的贡献大于迁移分支。这说明在当前复现实验中，显式语义信息对稳定排序有较明显帮助。但迁移分支仍然带来正向贡献，尤其在 Tail 和 Mid 品牌中可以补充目标城市不足的交互信号。因此，本文方案更适合作为 OTC-MF 的轻量增强模块，而不是完全替代原始跨城市框架。

8 局限性与未来工作

本文仍存在以下局限。第一，最终方案虽然相对 MF 基线取得稳定提升，但尚未超过原论文报告的 OTC-MF 平均结果。因此，本文更适合作为课程复现基础上的改进探索，而不是对原论文方法的全面替代。第二，term 表示质量仍然是瓶颈。如果

品牌和区域 term 构造不够准确，语义分支可能只能提供有限的重排序收益。第三，当前主要在固定 split 和主要随机种子下完成实验，未来可以进一步补充多 seed 结果，以验证稳定性。第四，本文仅在 MF 基线基础上完成最终融合，未来可以将同样的语义桥接和长尾自适应融合扩展到 LightGCN 等更强 backbone 上。

后续工作可以从三个方向展开：一是提升 term 矩阵质量，例如引入更可靠的品牌相似、区域相似和商业环境描述；二是设计更细粒度的迁移可靠性估计，避免不相似城市之间的负迁移；三是在保持可解释性的前提下，将语义 term 与图结构学习更紧密地结合。

9 结论

本文围绕 OTC-MF 跨城市选址推荐论文完成复现与改进实验。在复现阶段，我们重新训练并对齐 MF 基线，保存了代码、数据 split、模型分数和实验结果。在改进阶段，本文提出基于语义 term 桥接和城市-长尾自适应 RRF 融合的轻量方法。最终实验表明，该方法将平均 Recall@20 从 0.2428 提升到 0.2534，将平均 nDCG@20 从 0.1366 提升到 0.1401。分组分析和消融实验进一步说明，提升主要来自 Tail/Mid 品牌，语义 term、跨城市迁移和长尾分组融合均有贡献。整体来看，本文方法形成了一条较完整的复现实验闭环：从原论文问题分析，到 MF 基线对齐，再到语义增强和长尾自适应融合，最后通过主结果、分城市结果、分组结果和消融实验验证改进有效性。实验结果说明，即使复现基线尚未达到原论文的最优绝对数值，本文方法仍能在相同 split 和相同 MF 分数上取得稳定提升，证明显式语义信息与长尾自适应融合可以作为 OTC 类跨城市推荐框架的有效轻量补充，而非对原方法的全面替代。

代码与数据可用性

本文相关代码、固定数据 split、MF 模型与分数矩阵、term 特征和实验统计表已整理至公开仓库：<https://github.com/sss222eee/termbridge-fgwrec>。仓库结构如下：

- data/** 保存官方 split、ID 映射及品牌/区域 term 特征；
- artifacts/** 保存 MF Base、embedding、分数矩阵和随机种子；
- configs/, results/** 保存最终超参数、实验结果及论文图表；
- scripts/, src/otc/** 保存运行入口与数据、模型、OT/FGW 和评价实现。

References

- [1] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. 2009. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. Association for Computing Machinery, 758–759. doi: 10.1145/1571941.1572114
- [2] Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, Yongdong Zhang, and Meng Wang. 2020. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*. 639–648. doi: 10.1145/3397271.3401063
- [3] Xinhao Li, Xiangyu Zhao, Zihao Wang, Yang Duan, Yong Zhang, and Chunxiao Xing. 2024. Optimal Transport Enhanced Cross-City Site Recommendation. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '24)*. Association for Computing Machinery, New York, NY, USA, 1441–1451. doi: 10.1145/3626772.3657757
- [4] Gabriel Peyré and Marco Cuturi. 2019. *Computational Optimal Transport*. Now Publishers.
- [5] Steffen Rendle, Christoph Freudenthaler, Zeno Gantner, and Lars Schmidt-Thieme. 2009. BPR: Bayesian Personalized Ranking from Implicit Feedback. In *Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence*. 452–461.